

Predviđanje ishoda nogometnih utakmica

Karin Brajdić, Karlo Mezdić, Antun Slaviček, Luka Špiljak, Nikola Zrnc
Fakultet elektrotehnike i računarstva, Sveučilište u Zagrebu

18. siječnja 2026.

Sažetak—Ovaj rad bavi se primjenom različitih tehnika strojnog učenja za predviđanje ishoda nogometnih utakmica. Koristeći "European Soccer Database", razvijen je sustav koji sadrži povijesne podatke o utakmicama, attribute iz FIFA videoigre te kladioničarske koeficijente. Rad se bavi oblikovanjem ulaznih značajki, uključujući izračun ELO rejtinga, praćenje forme timova i agregiranje ocjena igrača. Uspoređeni su rezultati neuronske mreže, XGBoost algoritma i Random Forest klasifikatora. Eksperimentalni rezultati pokazuju da modeli postižu točnost od približno 50% za višeklasnu klasifikaciju (pobjeda, neriješeno, poraz) te oko 68% za binarnu klasifikaciju.

I. UVOD

Predviđanje ishoda nogometnih utakmica predstavlja problem zbog velikog broja varijabli koje utječu na rezultat, kao što je forma igrača, taktika, vremenski uvjeti pa i faktor sreće. Precizni modeli predviđanja imaju veliku primjenu, od industrije sportskog kladenja do analize klubova. Cilj ovog projekta je razviti robustan model koji može klasificirati ishod utakmice u jednu od tri kategorije: pobjeda domaćina, neriješeno ili pobjeda gosta na temelju statističkih i povijesnih značajki timova prije početka susreta.

II. POVEZANI RADOVI

Sudeći po broju objavljenih radova, temom predikcije ishoda sportskih događaja, osobito nogometnih utakmica, korištenjem metoda strojnog učenja ili statističke analize bavili su se brojni autori. Shodno tomu, opisani su različiti pristupi problemu. Problem se najčešće formulira kao višeklasna klasifikacija s trima ciljnim klasama, tipično u obliku „Win“, „Draw“ i „Loss“ odnosno „Home win“, „Draw“, „Away win“, ili kao binarni klasifikacijski problem s dvjema klasama „Win“ i „Loss“. U radovima se pritom najčešće koriste metode strojnog učenja poput logističke regresije, slučajnih šuma, XGBoost-a i SVM-a, dok se kao primjer primjene statističke analize može navesti korištenje Bayesovih mreža, što je izvedeno u radu [12], gdje je ostvarena točnost od 59%, što pokazuje da i relativno jednostavni probabilistički modeli mogu efektivno modelirati strukturu problema. Najčešće korišten skup podataka u

istraživanjima ove tematike povezan je uz englesku Premier ligu (EPL). Nad tim skupom podataka, u radu [5] najbolje se pokazao model slučajne šume koji je za binarni model bio najbolji među implementiranim, postigavši točnost od 67%, a za višeklasni 54%. U navedenom radu, za višeklasni model najbolje se pokazala logistička regresija s točnošću od 58%. U radu [11] Random Forest je postigao najvišu točnost od oko 69%, logistička regresija od oko 67%, XGBoost oko 67% i SVM oko 66% u predviđanju ishoda nogometnih utakmica.

U novijim radovima sve se više ističe važnost primjene neuronskih mreža u predikciji rezultata nogometnih utakmica, budući da takvi modeli mogu iskorištavati nelinearne odnose i složene interakcije između velikog broja značajki, kao i vremensku strukturu podataka. Mogu se pronaći primjeri upotrebe višeslojnih perceptrona konvolucijskih arhitektura te naprednih varijanti poput kvantnih neuronskih mreža. Višeslojni perceptron u radu [6] treniran na ranije spomenutom skupu podataka postiže ukupnu točnost od 57.7%, a također se ističe i uspješnošću predviđanja klase „Draw“. Još jedan od mogućih pristupa unutar dubokog učenja jest uporaba LSTM neuronske mreže, posebnog oblika RNN arhitekture koja rješava problem nestajućeg gradijenta te je prilagođena modeliranju vremenskih nizova i sekvenci utakmica kroz više sezona. [2] pokazuje da, na određenim skupovima podataka, jednostavnije arhitekture s potpuno povezanim (Dense) slojevima mogu biti konkurentne ili čak bolje od LSTM-a, pri čemu se implementacijom LSTM mreže postiže maksimalna točnost od 52.1%, koja se povećala na 52.5% uporabom jednostavnijeg modela neuronske mreže samo s potpuno povezanim slojevima, bez LSTM sloja.

Mnogi radovi, poput [2][4][5], ističu da se pri formulaciji problema predviđanja ishoda utakmice kao višeklasnog klasifikacijskog zadatka s ciljnim varijablama „Win“, „Loss“ i „Draw“ javlja poteškoća u predviđanju klase „Draw“, koja se u većini istraživanja ili vrlo rijetko ispravno predviđa ili se u potpunosti zanemaruje. Ova pojava objašnjava se izraženom neuravnoteženošću skupa podataka, odnosno znatno manjim brojem primjera te klase u

odnosu na ostale dvije, zbog čega model u procesu učenja teži favoriziranju dominantnijih klasa. Kao jedno od najčešćih praktičnih rješenja ovoga problema, brojni autori pribjegavaju reformulaciji zadatka u binarni klasifikacijski problem, pri čemu se klasa „Draw“ ili potpuno izostavlja, ili se spaja s klasom „Loss“, čime se umjetno uravnotežuje distribucija ciljne varijable. Takav pristup u pravilu dovodi do zamjetnog porasta ukupne točnosti modela, iako pritom dolazi do gubitka informacije o specifičnoj kategoriji neriješenih utakmica.

Također, radovi poput [5] naglašavaju ključnu ulogu odabira značajki i inženjerstva značajki, odnosno implementacije novih, izvedenih varijabli koje se računaju na temelju postojećih podataka, a koje bolje odražavaju stvarnu snagu i formu momčadi te kontekst utakmice. U tom se smislu kao osobito informativne pokazuju agregirane metrike poput omjera pobjeda i poraza u posljednjim utakmicama, razlike u postignutim i primljenim pogocima te FIFA rejtinga. Rezultati pokazuju da se uvođenjem pažljivo dizajniranih značajki može postići mjerljivo poboljšanje točnosti modela, uz istodobno smanjenje dimenzionalnosti i računske složenosti.

Većina radova usmjerena na predikciju ishoda nogometnih utakmica nastoji takve modele iskoristiti za maksimiziranje profita, odnosno usporedbu s modelom dobivenih vjerojatnosti s kvotama kladionica [8]. Dodatno, dio istraživanja fokusira se na optimizaciju izbora i kombinacija nogometaša, gdje se predikcije performansi pojedinih igrača koriste za odabir sastava koji maksimizira vjerojatnost željenog ishoda, odnosno pobjede [2].


U ovome radu implementiran je prilagođeni model neuronske mreže te je njegova točnost, ostvarena treniranjem nad odabranim skupom podataka, uspoređena s točnostima modela strojnog učenja XG-Boost i slučajne šume, kao i s objavljenim modelom neuronske mreže. Problem predikcije ishoda utakmica promatran je kao višeklasni, ali i binarni klasifikacijski zadatak, s ciljem detaljnijeg ispitivanja problematike predviđanja ciljne varijable „Draw“. Kako bi se procijenila stvarna učinkovitost razvijenog modela, dobiveni rezultati dodatno su uspoređeni s rezultatima temeljenima na kladioničarskim koeficijentima za pojedine utakmice.

III. OBRADA PODATAKA

A. Baza podataka

Projekt koristi [European Soccer Database](#) s platforme Kaggle (autora Hugo Mathien). Baza sadrži detaljne podatke o više od 25.000 utakmica, 11 europskih liga (od 2008. do 2016. godine), atributi igrača i timova (preuzete iz video igre FIFA) te kladioničarske koeficijente. Analizom distribucije ishoda utakmica uočen je očekivani disbalans klasa, gdje domaćini

pobjeđuju u većini slučajeva, dok su remi i pobjeda gosta rjeđi događaji.



Slika 1. Raspodjela ishoda utakmica (1: Domaćin, 0: Remi, 2: Gost).

Zbog manjka primjera za neriješene ishode, očekuje se da će model imati najslabije performanse upravo u toj klasi.

Baza je strukturirana u relacijske tablice od kojih su nam najvažnije:

- **Match** : sadrži sve odigrane utakmice, njihove rezultate te igrače koji su igrali na utakmici,
- **Player_Attributes** : sadrži informacije o kvaliteti i ocjenama igrača,
- **Team_Attributes** : sadrži informacije o timovima i njihovoj kvaliteti igre

B. Priprema podataka i oblikovanje značajki

Sirovi podaci zahtijevali su opsežnu predobradu kako bi bili pogodni za treniranje neuronske mreže. Proces je uključivao sljedeće korake:


- 1) **Vremenska sinkronizacija**: Atributi igrača i timova mijenjaju se kroz vrijeme. Za svaku utakmicu implementiran je algoritam koji dohvaća atribut (npr. *overall_rating*, *buildUpPlaySpeed*) koji su bili važeći na datum odigravanja utakmice.
- 2) **Agregacija kvalitete**: Umjesto korištenja 22 zasebna ulaza za svakog igrača, izračunat je prosječni rejting startne postave domaćina (*home_team_rating*) i gosta (*away_team_rating*).
- 3) **Izračun forme**: Kreirane su značajke koje prate učinak tima u zadnjih 5 utakmica. Osim klasičnog bodovnog prosjeka, implementirana je i **težinska forma** (*weighted form*) gdje novije utakmice imaju veći utjecaj na izračun, te *Goal Momentum* koji prati gol-razliku u zadnjem periodu.
- 4) **ELO Rejting**: Implementiran je dinamički ELO sustav koji se ažurira nakon svake utakmice. ELO sustav se pokazao robusnijim indikatorom dugoročne kvalitete od ligaške tablice.

5) **Kontekstualne značajke:** Uključuju *League Strength Index* (normalizacija snage tima s obzirom na ligu) te *Head-to-Head* povijest međusobnih omjera.

Primjer isječka glavne tablice s izračunatim značajkama prikazan je u Tablici I.

Tablica I
PRIMJER ISJEČKA GLAVNE TABLICE S IZRAČUNATIM ZNAČAJKAMA

Home rating	Away rating	Rating diff	ELO diff	Result
76.090909	75.727273	0.363636	26.795823	Pobjeda domaćina(1)
78.454545	75.000000	3.454545	152.739799	Neriješeno(0)
76.181818	71.454545	-4.727273	131.354939	Pobjeda gosta(2)




Slika 3. Prikaz korelacije odabranih značajki s ishodom utakmice.

C. Priprema podataka za treniranje modela

Prije ulaska u model, podaci su prošli finalnu obradu:

- **Tretiranje nedostajućih vrijednosti:** Nedostajuće vrijednosti (NaN) u atributima igrača popunjene su srednjom vrijednošću (mean) kako bi se očuvao integritet skupa podataka.
- **Podjela skupa podataka (Temporal Split):** Zbog vremenske prirode problema, podaci nisu dijeljeni nasumično. Za treniranje su korištene sezone od 2008. do 2015., dok je sezona 2015./2016. ostavljena isključivo za testiranje. Ovim se sprječava curenje informacija iz budućnosti (data leakage - korištenje budućih utakmica za predviđanje prošlih). Dinamičnost podataka prikazana je na Slici 2, gdje je vidljivo kako snaga tima (ELO) nije statična varijabla, već oscilira kroz godine.



Slika 2. Prikaz promjene ELO rejtinga za Barcelonu (2008-2016). Oscilacije potvrđuju potrebu za vremenskom podjelom podataka.

- **Normalizacija:** Numeričke značajke skalirane su koristeći *StandardScaler* na distribuciju srednje vrijednosti 0 i devijacije 1, dok su kategoričke varijable (poput lige) enkodirane *One-Hot* metodom.

Matrica korelacije (Slika 3) prikazuje međusobne odnose ključnih značajki. Najveća korelacija s ishodom utakmice primijećena je kod varijabli *elo_diff* i *rating_diff*, što potvrđuje da je razlika u kvaliteti timova najvažniji prediktor. S druge strane, taktički atributi poput brzine igre (*buildUpPlaySpeed*) pokazuju zanemarivu linearnu korelaciju s konačnim ishodom.


IV. IMPLEMENTACIJA MODELA

A. Neuronska mreža

1) *Dizajn i arhitektura mreže:* Dizajn arhitekture neuronske mreže za predviđanje ishoda nogometnih utakmica zahtijevao je istraživanje prostora hiperparametara. Fokus je bio na prolaženju ravnoteže između kapaciteta modela i sposobnosti generalizacije. Arhitektura predloženih modela temelji se na višeslojnim potpuno povezanim strukturama. Svaki linearni sloj popraćen je normalizacijskim slojem (BatchNorm), dok je za prevenciju prekomjernog učenja i poboljšanu regularizaciju modela korišten Dropout sloj za deaktivaciju neurona s faktorom 0.3. Eksperiment je proveden na zadatku binarne klasifikacije ishoda (Pobjeda/Gubitak). U prvoj fazi eksperimenta ispitivan je utjecaj dubine neuronske mreže na preciznost klasifikacije. Korištenjem unakrsne validacije (eng. cross-validation) testirane su sljedeće konfiguracije skrivenih slojeva:

- [32, 64, 32]
- [32, 64, 64, 32]
- [32, 64, 128, 64, 32]

Rezultati prikazani na Slika 4 pokazuju kako najplići model ([32, 64, 32]) postiže najbolje rezultate i najmanji validacijski gubitak. Povećanje broja slojeva nije rezultiralo poboljšanjem generalizacije modela, ali nije ni dovelo do prenaučenosti. Validacijski gubitci po epohama za sve konfiguracije mreža otprilike su jednaki.




Slika 4. Validacijski gubitak tijekom treniranja za različite arhitekture skrivenih slojeva.

Nakon testiranja optimalne dubine mreže, provodi se evaluacija optimalnog broja neurona unutar slojeva. Za sve testirane dubine mreže rezultati su vrlo slični, stoga se u ovom dijelu eksperimenta koristi mreža od 4 skrivena sloja s konfiguracijama:

- [32, 64, 64, 32]
- [64, 128, 128, 64]
- [128, 256, 128, 64]
- [128, 256, 512, 128]
- [256, 512, 1024, 512]

Rezultati na Slika 5 pokazuju da nema jasne povezanosti između bolje generalizacije i većeg modela. Mreža s najvećim brojem parametara postiže najbolji validacijski gubitak, ali razlika je vrlo mala (0.05). Na toj mreži također dolazi do brže prenaučivosti.



Slika 5. Validacijski gubitak tijekom treniranja za različit broj neurona u slojevima mreže.

2) *Treniranje i ostali hiperparametri:* Osim arhitekture mreže, bitni su i drugi hiperparametri:

- **Funkcija gubitka:** Za višeklasnu klasifikaciju ishoda (Pobjeda/Gubitak/Remi) korištena

je funkcija unakrsne entropije (Cross-Entropy Loss), a za binarnu klasifikaciju ishoda je korištena binarna verzija unakrsne entropije (Binary Cross-Entropy Loss).

- **Optimizator:** Optimizacija parametara provedena je pomoću optimizatora Adam (eng. Adaptive Moment Estimation) s početnom stopom učenja od 0.005. Korištena je manja stopa učenja zbog stabilnosti učenja, također je korišteno i dinamičko prilagođavanje stope učenja pomoću ReduceLROnPlateau scheduler-a koji smanjuje stopu učenja za faktor 0.6 ako na validacijskom skupu nema poboljšanja kroz 20 uzastopnih epoha.
- **Rano zaustavljanje:** Kako bismo izbjegli prenaučivost, mehanizam ranog prekidanja zaustavlja proces učenja ako se validacijski gubitak ne smanji unutar 50 epoha. Finalni model koristi težine s kojima je postigao najmanji validacijski gubitak tijekom treniranja.

3) *Rezultati:* Kao što smo napomenuli prije, u ovom radu promatrali smo i binarnu klasifikaciju (Pobjeda/Gubitak) i višeklasnu klasifikaciju (Pobjeda/Gubitak/Remi). Rezultati su prikazani odvojeno:


4) *Binarna klasifikacija (Pobjeda/Gubitak):* U ovom scenariju, iz skupa podataka uklonjene su sve utakmice koje su završile izjednačeno, te je model treniran samo na utakmicama s jednim od timova kao pobjednikom. Na takvom skupu podataka model postiže točnost (eng. accuracy) od 68%.

Class	Precision	Recall	F1-score	Support
0 (pobjeda domaćina)	0.69	0.82	0.75	1459
1 (pobjeda gosta)	0.65	0.47	0.54	1012
Accuracy			0.68	
Macro avg	0.67	0.65	0.65	2471
Weighted avg	0.67	0.68	0.67	2471

Tablica II
KLASIFIKACIJSKI IZVJEŠTAJ ZA BINARNU KLASIFIKACIJU
(POBJEDA/GUBITAK)

Analiza rezultata pokazuje da model bolje prepoznaje pobjede domaćina (klasa 0), dok je klasifikacija pobjede gosta nešto slabija. F1-mjera (0.65) i odziv (recall) pokazuju umjerenu sposobnost modela u detekciji stvarnih pobjeda.

5) *Višeklasna klasifikacija (pobjeda/gubitak/remi):* Model je treniran na cjelokupnom skupu podataka s tri klase, te je najbolji model postigao točnost od 51 %. Rezultati pokazuju da model snažno favorizira najčešće zastupljenu klasu (pobjedu domaćina), dok je detekcija remija i pobjede domaćina slabija. F1-mjera od 0.39 ukazuje na neuravnoteženost između klase.



Slika 9. Konfuzijska matrica za XGB model.

Možemo primijetiti da su rezultati dobiveni korištenjem XGBoost modela vrlo slični rezultatima dobivenim s ostalim modelima.


C. Random forest

Random Forest je ansambl algoritam strojnog učenja koji tijekom treniranja gradi velik broj stabala odluke. Svako stablo trenira se na slučajnom podskupu podataka i slučajnom podskupu značajki. Konačna predikcija dobiva se glasovanjem u slučaju klasifikacije ili prosjekom u slučaju regresije. Kao i u prethodnim slučajevima, algoritam će se koristiti za binarnu klasifikaciju pobjeda–poraz te višerazrednu klasifikaciju pobjeda–poraz–neriješeno.

1) *Binarna klasifikacija*: U slučaju binarne klasifikacije, model je postigao točnost od 68.9 %, što ukazuje na umjerenu sposobnost ispravnog klasificiranja ishoda utakmica. Preciznost za pozitivnu klasu iznosi 64,4 %, što znači da u približno dvije trećine slučajeva kada model predvidi pobjedu, momčad zaista i pobjedi. Međutim, odziv od samo 43,0 % ukazuje na to da model propušta prepoznati značajan broj stvarnih pobjeda. F1-mjera iznosi 0,52, što ukazuje na neuravnoteženost između preciznosti i odziva. Konfuzijska matrica pokazuje da model znatno bolje prepoznaje klasu 0 nego klasu 1, što se može djelomično pripisati neuravnoteženosti skupa podataka. Drugim riječima, model je sklon predviđanju pobjede domaćina te češće izbjegava predviđanje pobjede gostiju. Zbog toga je broj lažno negativnih predikcija razmjerno veći od broj lažno pozitivnih.

Tablica V
KLASIFIKACIJSKI IZVJEŠTAJ ZA BINARNU KLASIFIKACIJU

Class	Precision	Recall	F1-score	Support
0	0.70	0.85	0.77	3575
1	0.64	0.43	0.52	2240
Accuracy	0.69			
Macro avg	0.67	0.64	0.64	5815
Weighted avg	0.68	0.69	0.67	5851




Slika 10. Konfuzijska matrica binarne klasifikacije

2) *Višerazredna klasifikacija*: U slučaju klasifikacije ishoda utakmice u tri klase, postignuta točnost iznosi 50.7%, što je znatno niže od binarnog slučaja. Makro-preciznost (0.43), makro-odziv (0.43) i makro F1-mjera (0.39) ukazuju na to da model ima poteškoće u ravnomjernom učenju svih klasa. Model ponovo vrlo dobro prepoznaje pobjedu domaćina (odziv = 0,82), dok klasu neriješenog ishoda gotovo uopće ne prepoznaje (odziv = 0,04). Rezultati za pobjedu gosta su umjereni, ali i dalje slabiji od dominantne klase. Ovakvo ponašanje modela ukazuje na snažnu pristranost prema najzastupljenijoj klasi te dodatno potvrđuje da je problem neuravnoteženosti klase izraženiji u višeklasnoj formulaciji zadatka (Slika 11.).

Class	Precision	Recall	F1-score	Support
0	0.27	0.04	0.08	1979
1	0.53	0.82	0.64	3575
2	0.48	0.42	0.45	2240
Accuracy	0.51			
Macro avg	0.43	0.43	0.39	7794
Weighted avg	0.45	0.51	0.44	7794

Tablica VI
KLASIFIKACIJSKI IZVJEŠTAJ ZA VIŠERAZREDNU
KLASIFIKACIJU

3) *Optimizacija parametara*: Za dodatnu optimizaciju hiperparametara modela, provedeni su postupci pretraživanja po rešetci za binarnu i višerazrednu klasifikaciju. Parametri pretraživanja uključivali su broj stabala, maksimalna dubina te minimalni broj uzoraka potreban za grananje i list stabla. U slučaju binarne klasifikacije, postignut je blagi napredak u točnosti i preciznosti, dok u slučaju više razredne klasifikacije, nije postignut značajan napredak. To dodatno potvrđuje da su rezultati snažno ograničeni neuravnoteženošću klasa.




Slika 11. Konfuzijska matrica višerazredne klasifikacije

Tablica VII

NAJBOLJI PARAMETRI I METRIKE MODELA RANDOM FOREST ZA BINARNU I VIŠERAZREDNU KLASIFIKACIJU

Parametar / Metrika	Binarna klasifikacija	Višerazredna klasifikacija
max_depth	unlimited	unlimited
min_samples_leaf	1	1
min_samples_split	5	2
n_estimators	100	100
Best test F1 score	0.5232	0.3974
Accuracy	0.6913	0.5008
Precision	0.6459	0.4302



Slika 12. Heatmapa pretraživanja po rešetci binarne klasifikacije

D. Postojeća neuronska mreža

Za uspoređivanje modela uzeli smo gotovu neuronsku mrežu preuzetu s <https://github.com/vegardhaneberg/European-Soccer-Predictions> proizvedenu kao rješenje za isti dataset kao i naš. Na githubu nije bio dostupan gotov model. Mreža se trenirala na našim pripremljenim podacima dataseta.

Model je treniran za višerazrednu klasifikaciju (*draw*, *home win*, *away win*). Dobiveni rezultati tre-

niranja prikazani su u nastavku.

Metrika	Vrijednost
Accuracy	0.497294046903187
Precision (avg)	0.3946660359537007
Macro F1	0.3627966367744466

Tablica VIII

UKUPNE METRIKE MODELA.

Klasa	Precision	Recall	F1-score	Support
0 (draw)	0.20	0.00	0.01	855
1 (home)	0.51	0.84	0.63	1459
2 (away)	0.48	0.43	0.45	1012
macro avg	0.39	0.42	0.36	3326
weighted avg	0.42	0.50	0.42	3326

Tablica IX

DETAJLNI KLASIFIKACIJSKI IZVJEŠTAJ ZA TWO-LAYER NN.

	Pred: 0	Pred: 1	Pred: 2
Akt: 0	3	617	235
Akt: 1	2	1219	238
Akt: 2	10	570	432

Tablica X

MATRICA KONFUZIJE (REDOVI = STVARNE KLASJE, STUPCI = PREDVIDENE KLASJE).

Model postiže približno 49.7% točnosti na skupu za evaluaciju. Najistaknutiji problem je gotovo potpuna nemogućnost prepoznavanja ishoda *draw* (klasa 0): recall je praktički 0, što znači da model gotovo nikad ne predviđa remi. S druge strane, model vrlo pouzdano prepoznaje *home* ishode (recall 0.84), dok je prepoznavanje *away* ishoda srednje kvalitetno (recall 0.43). Matrica konfuzije pokazuje da se veliki dio stvarnih *draw* i *away* utakmica klasificira kao *home*.

V. USPOREDBA MODELA

Nakon implementacije i evaluacije pojedinačnih modela (Neuronska mreža, XGBoost i Random Forest), provedena je usporedna analiza kako bi se utvrdilo koji algoritam najbolje generalizira na novim podacima. Usporedba je napravljena u tri scenarija: višerazredna klasifikacija (pobjeda domaćina, neriješeno, pobjeda gosta), binarna klasifikacija te usporedba s kladioničarskim koeficijentima.

A. Višerazredna klasifikacija

U problemu predviđanja točnog ishoda utakmice (klase 1, 0, 2), svi modeli susreću se s izazovom niske predvidljivosti neriješenih rezultata (Draw). Analiza metrika pokazuje izrazito niske vrijednosti F1-mjere za tu klasu, što sugerira da statističke značajke timova prije utakmice nisu dovoljne za razlikovanje situacija u kojima će doći do podjele bodova.


Na slici 13 prikazana je vizualna usporedba točnosti. Vidljivo je da svi modeli, uključujući i referentni model preuzet s otvorenih izvora, konvergiraju prema točnosti od približno 50%. Troklasne

Model	Accuracy	Precision (avg)	F1-score (avg)
Neuronska mreža	0.50	0.43	0.42
XGBoost	0.52	0.45	0.46
Random Forest	0.51	0.44	0.44
Two-Layer NN (github)	0.49	0.39	0.36

Tablica XI

USPOREDBA PERFORMANSI NA VIŠERAZREDNOJ KLASIFIKACIJI

varijante imaju accuracy od 0.49 do 0.504. Glavna slabost svih modela je detekcija izjednačenog (klasa 0), recall je blizu 0 za svaki model, a naša neuronska mreža je najbolja s 0.15 što i dalje nije dovoljno. Modeli najčešće predviđaju *home win* (klasa 1) s recallom između 0.79 i 0.89. XGBoost ima najbolji accuracy, no uopće ne predviđa izjednačenje. Neuronska mreža ima najbolju detekciju za izjednačeno, no ima sveukupno najgori accuracy. Random Forest ima sličan accuracy ko ostali, no prepoznaje niski broj izjednačenih utakmica.



Slika 13. Usporedba modela na problemu višerazredne klasifikacije

B. Binarna klasifikacija

Kako bi se ispitala mogućnost poboljšanja performansi pojednostavljenjem problema, provedena je binarna klasifikacija (pobjeda domaćina vs. pobjeda gosta). U ovom scenariju, svi testirani algoritmi (NN, XGBoost, RF) postižu gotovo identičnu točnost od približno 67% – 68%.

Model	Accuracy	Home Recall / F1	Away Recall / F1
Neuronska mreža (binary)	0.67	0.84 / 0.75	0.43 / 0.52
XGBoost (binary)	0.67	0.86 / 0.76	0.40 / 0.50
Random Forest (binary)	0.675	0.87 / 0.76	0.40 / 0.50


Tablica XII

USPOREDBA 2-OUTPUT MODELA (HOME WIN / AWAY WIN).

Sve binarne varijante imaju vrlo sličan accuracy, krećući se oko 0.67 za sve tri metode (Neuronska mreža, XGBoost i Random Forest). Svi modeli pokazuju izražen bias prema *home* pobjedama (klasa 0), s vrlo visokim recallom između 0.84 i 0.87, dok je detekcija *away* pobjeda (klasa 1) značajno slabija, s recallom oko 0.40–0.43. XGBoost i Random Forest daju gotovo identične rezultate, dok Neuronska mreža

postiže nešto bolji balans između precisiona i recall-a, ali i dalje pati od istog obrasca prekomjernog predviđanja domaćih pobjeda.

Usporedba performansi na binarnom problemu prikazana je na slici 14.



Slika 14. Usporedba modela na problemu binarne klasifikacije

C. Usporedba s kladionicom Bet365

Kako bismo dobili realnu sliku o kvaliteti modela, rezultate smo usporedili s predviđanjima kladionice Bet365. Kladioničarski favorit (ishod s najmanjim koeficijentom) na istom testnom skupu postiže točnost od **50.57%**.

Činjenica da naši modeli postižu točnost od otprilike 50%, pokazuje da su modeli uspjeli dosegnuti razinu industrijskih predviđanja koristeći isključivo dostupne povijesne podatke i FIFA attribute, bez uvida u promjene koeficijenata u stvarnom vremenu.

D. Zaključak usporedbe

Analizom dobivenih rezultata možemo izvesti nekoliko ključnih zaključaka:

- **Limit predvidljivosti:** Svi modeli postižu slične rezultate, što ukazuje na dosegnuti limit predvidljivosti za ovaj skup podataka. Nogomet je inherentno stohastičan sustav gdje faktori poput sudačkih pogrešaka, crvenih kartona, sreće ili trenutne inspiracije pojedinca predstavljaju nepredvidiv šum.
- **Problem klase "Neriješeno":** Modeli sustavno griješe kod neriješenih rezultata jer se statistički profil utakmice koja završi remijem gotovo ne razlikuje od one u kojoj favorit ostvari minimalnu pobjedu.
- **Usporedba s industrijom:** Naši modeli približili su se točnosti kladionica. To potvrđuje da su odabrane značajke (ELO, FIFA ocjene, forma) relevantne i da model ispravno uči uzorke, ali mu nedostaju informacije u stvarnom vremenu (ozljede na dan utakmice, stanje zdravlja igrača) koje imaju kladionice.

- **Prednost binarne klasifikacije:** Binarna klasifikacija postiže znatno veću točnost ($\approx 68\%$) iz geometrijskog razloga. Uklanjanjem klase "neriješeno" (koja se u prostoru značajki često preklapa s druge dvije klase), granica odluke (*decision boundary*) postaje linearno separabilna. Model lakše uči razliku između "favorit pobjeđuje" i "favorit gubi" nego nijansu između tijesne pobjede i neriješenog rezultata.

VI. USPOREDBA S DRUGIM RADOVIMA

Usporedba modela implementiranih u ovome radu s rezultatima objavljenima u literaturi nije u potpunosti izravna, ponajprije zbog razlika u korištenim skupovima podataka, odabiru značajki i samim arhitekturama modela. Unatoč tome, na temelju metrike točnosti moguće je dobiti okvirnu sliku o tome gdje se dobiveni rezultati nalaze u odnosu na druge radove koji se bave predikcijom ishoda nogometnih utakmica.

U kontekstu neuronskih mreža, [8] koristi potpuno povezanu mrežu s dva skrivena sloja od 300 i 100 neurona, kojom na EPL skupu podataka postiže točnost od približno 56,4%. Ta vrijednost nadmašuje točnost od 50% ostvarenu u ovome radu korištenjem tuđe neuronske mreže, koja također sadrži dva skrivena sloja. U istom radu [8] autori zatim uvode LSTM arhitekturu kako bi ispitali važnost vremenske ovisnosti u sekvencama utakmica, pri čemu točnost raste na 58,2%, dok [2] uporabom LSTM mreže bilježi skromniju točnost od 52,5%, što pokazuje da LSTM ne jamči nužno značajno poboljšanje u svim kontekstima. [9] prikazuje mogućnost korištenja konvolucijskih neuronskih mreža (CNN) za rješavanje problema predikcije ishoda nogometne utakmice te postiže točnost od približno 55,31% i pritom navodi da time nadmašuje predikcije stručnjaka te predikcije izvedene iz kladioničarskih koeficijenata, čija se točnost kreće oko 52%. Sličnu razinu točnosti, oko 52,8%, postiže i [3], koji koristi duboku, potpuno povezanu neuronsku mrežu s tri skrivena sloja i pažljivo optimiziranim hiperparametrima. Time se dodatno potvrđuje da se većina modela neuronskih mreža za troklasnu predikciju ishoda utakmica kreće u rasponu od 53% do 58%, što je više od 51% postignutih u ovom radu implementacijom vlastite mreže s četiri skrivena sloja.

U ovome su radu, uz neuronske mreže, implementirani i modeli XGBoost i Random Forest kako bi se ispitao potencijal standardnih metoda strojnog učenja u odnosu na duboko učenje. U literaturi se za višeklasnu klasifikaciju tipične točnosti Random Foresta kreću otprilike od 53% do 58%, ovisno o skupu podataka, značajkama i preobradi podataka [5], dok XGBoost u različitim radovima i projektima postiže približno između 55% i 62% [6][13]. Uspoređujući

navedene raspone vrijednosti točnosti s rezultatima ovoga rada, može se uočiti da su dobivene točnosti višeklasnih modela od 51% za Random Forest i 50,42% za XGBoost nešto niže te ostavljaju prostor poboljšanju.

Posebno je zanimljiva usporedba binarnih modela, u kojima se problem reducira na predikciju pobjede naspram poraza. U ovome radu binarni Random Forest model nadjačava XGBoost model i postiže točnost od oko 69%, što ga smješta u rang s rezultatima u literaturi, gdje se točnosti binarnih klasifikatora za ovaj problem tipično kreću između 60% i 70% za Random Forest te između 62% i 70% za XGBoost. Time se može zaključiti da, iako višeklasni modeli iz ovoga rada ostvaruju nešto niže rezultate od najboljih prijavljenih u literaturi, binarni modeli pokazuju optimistične i konkurentne performanse te su u skladu s onim što se u praksi postiže drugim suvremenim pristupima na srodnim skupovima podataka.

LITERATURA

- [1] R. P. Bunker and F. Thabthah, *A machine learning framework for sport result prediction*, Auckland University of Technology, 2017.
- [2] N. Danisik, P. Lacko, and M. Farkas, *Football Match Prediction using Players Attributes*, Faculty of Informatics and Information Technologies, Slovak University of Technology, 2018.
- [3] L. E. Luiz, G. Fialho, and J. P. Teixeira, "Is Football Unpredictable? Predicting Matches Using Neural Networks," *Forecasting*, vol. 6, pp. 1152–1168, 2024.
- [4] T. Wang, Z. Zhang, and S. Zhu, "Machine Learning-Based Football Match Prediction System," in *Proc. 6th Int. Conf. on Computing and Data Science*, 2024.
- [5] B. S. Choi, L. K. Foo, and S.-L. Chua, "Predicting Football Match Outcomes With Machine Learning Approaches," *MENDEL*, 2023.
- [6] L. Huynh, "Enhancing Football Match Predictions through AI and Machine Learning in the English Premier League," *The National High School Journal of Science*, 2024.
- [7] E. Esme and M. S. Kiran, "Prediction of Football Match Outcomes Based on Bookmaker Odds by Using k-Nearest Neighbor Algorithm," *International Journal of Machine Learning and Computing*, vol. 8, no. 1, 2018.
- [8] A. A. Awadallah and R. Khandelwal, *Football Match Prediction Using Deep Learning (Recurrent Neural Network)*, Stanford University, 2020.
- [9] T. Satyapanich and A. Somkheawwan, "Predicting Game Results for Football League Using Deep Learning," in *Proc. 27th Int. Computer Science and Engineering Conference (ICSEC)*, IEEE, 2023.
- [10] Y. F. Alfredo and S. M. Isa, "Football Match Prediction with Tree Based Model Classification," *I.J. Intelligent Systems and Applications*, vol. 7, pp. 20–28, 2019.
- [11] E. F. E. Atta Mills, Z. Deng, Z. Zhong, and J. Li, "Data-driven Prediction of Soccer Outcomes Using Enhanced Machine and Deep Learning Techniques," *Journal of Big Data*, 2024.
- [12] A. Joseph, N. E. Fenton, and M. Neil, "Predicting football results using bayesian nets and other machine learning techniques," *Knowledge-Based Systems*, vol. 19, no. 7, pp. 544–553, 2006.
- [13] Steen D., *Predicting Professional Soccer Match Outcomes Using Team Statistics and Machine Learning*, GitHub repository, https://github.com/douglaspssteen/Predict_EPL_Matches?tab=readme-ov-file#random-forest, accessed January 15, 2026.