

Predviđanje ishoda nogometnih utakmica

Antun Slaviček, Karin Brajdić, Nikola Zrnc, Karlo Mezdić, Luka Špiljak

14. siječnja 2026.

Sažetak

Ovaj rad bavi se primjenom različitih tehnika strojnog učenja za predviđanje ishoda nogometnih utakmica. Koristeći "European Soccer Database", razvijen je sustav koji sadrži povijesne podatke o utakmicama, atribute iz FIFA videoigre te kladioničarske koeficijente. Rad se bavi oblikovanjem ulaznih značajki, uključujući izračun ELO rejtinga, praćenje forme timova i agregiranje ocjena igrača. Uspoređeni su rezultati neuronske mreže, XGBoost algoritma i Random Forest klasifikatora. Eksperimentalni rezultati pokazuju da modeli postižu točnost od približno 50-52% za višeklasnu klasifikaciju (pobjeda, neriješeno, poraz) te oko 69% za binarnu klasifikaciju.


1 Uvod

Predviđanje ishoda nogometnih utakmica predstavlja problem zbog velikog broja varijabli koje utječu na rezultat, kao što je forma igrača, taktika, vremenski uvjeti pa i faktor sreće. Precizni modeli predviđanja imaju veliku primjenu, od industrije sportskog klađenja do analize klubova. Cilj ovog projekta je razviti robustan model koji može klasificirati ishod utakmice u jednu od tri kategorije: pobjeda domaćina, neriješeno ili pobjeda gosta na temelju statističkih i povijesnih značajki timova prije početka susreta.

2 Obrada podataka

2.1 Baza podataka

Projekt koristi [European Soccer Database](#) s platforme Kaggle (autora Hugo Mathien). Baza sadrži detaljne podatke o više od 25.000 utakmica, 11 europskih liga (od 2008. do 2016. godine), atribute igrača i timova (preuzete iz video igre FIFA) te kladioničarske koeficijente. Analizom distribucije ishoda utakmica uočen je očekivani disbalans klasa, gdje domaćini pobjeđuju u većini slučajeva, dok su remi i pobjeda gosta rjeđi događaji.



Slika 1: Raspodjela ishoda utakmica (1: Domaćin, 0: Remi, 2: Gost).

Zbog manjka primjera za neriješene ishode, očekuje se da će model imati najslabije performanse upravo u toj klasi.

Baza je strukturirana u relacijske tablice od kojih su nam najvažnije:

- **Match** : sadrži sve odigrane utakmice, njihove rezultate te igrače koji su igrali na utakmici,
- **Player_Attributes** : sadrži informacije o kvaliteti i ocjenama igrača
- **Team_Attributes** : sadrži informacije o timovima i njihovoj kvaliteti igre

2.2 Priprema podataka i oblikovanje značajki

Sirovi podaci zahtijevali su opsežnu predobradu kako bi bili pogodni za treniranje neuronske mreže. Proces je uključivao sljedeće korake:

1. **Vremenska sinkronizacija**: Atributi igrača i timova mijenjaju se kroz vrijeme. Za svaku utakmicu implementiran je algoritam koji dohvaća attribute (npr. *overall_rating*, *buildUpPlaySpeed*) koji su bili važeći na datum odigravanja utakmice.
2. **Agregacija kvalitete**: Umjesto korištenja 22 zasebna ulaza za svakog igrača, izračunat je prosječni rejting startne postavke domaćina (*home_team_rating*) i gosta (*away_team_rating*).
3. **Izračun forme**: Kreirane su značajke koje prate učinak tima u zadnjih 5 utakmica. Osim klasičnog bodovnog prosjeka, implementirana je i **težinska forma** (*weighted form*) gdje novije utakmice imaju veći utjecaj na izračun, te *Goal Momentum* koji prati gol-razliku u zadnjem periodu.
4. **ELO Rejting**: Implementiran je dinamički ELO sustav koji se ažurira nakon svake utakmice. ELO sustav se pokazao robusnijim indikatorom dugoročne kvalitete od ligaške tablice.
5. **Kontekstualne značajke**: Uključuju *League Strength Index* (normalizacija snage tima s obzirom na ligu) te *Head-to-Head* povijest međusobnih omjera.

Primjer isječka glavne tablice s izračunatim značajkama prikazan je u Tablici 1.


Tablica 1: Primjer isječka glavne tablice s izračunatim značajkama

Home rating	Away rating	Rating diff	ELO diff	Result
76.090909	75.727273	0.363636	26.795823	Pobjeda domaćina(1)
78.454545	75.000000	3.454545	152.739799	Neriješeno(0)
76.181818	71.454545	-4.727273	131.354939	Pobjeda gosta(2)


2.3 Priprema podataka za treniranje modela

Prije ulaska u model, podaci su prošli finalnu obradu:

- **Tretiranje nedostajućih vrijednosti**: Nedostajuće vrijednosti (NaN) u atributima igrača popunjene su srednjom vrijednošću (mean) kako bi se očuvao integritet skupa podataka.
- **Podjela skupa podataka (Temporal Split)**: Zbog vremenske prirode problema, podaci nisu dijeljeni nasumično. Za treniranje su korištene sezone od 2008. do 2015., dok je sezona 2015./2016. ostavljena isključivo za testiranje. Ovim se sprječava curenje informacija iz budućnosti (data leakage - korištenje budućih utakmica za predviđanje prošlih). Dinamičnost podataka prikazana je na Slici 2, gdje je vidljivo kako snaga tima (ELO) nije statična varijabla, već oscilira kroz godine.
- **Normalizacija**: Numeričke značajke skalirane su koristeći *StandardScaler* na distribuciju srednje vrijednosti 0 i devijacije 1, dok su kategoričke varijable (poput lige) enkodirane *One-Hot* metodom.



Slika 2: Prikaz promjene ELO rejtinga za Barcelonu (2008-2016). Oscilacije potvrđuju potrebu za vremenskom podjelom podataka.



Slika 3: Prikaz korelacije odabranih značajki s ishodom utakmice.

Matrica korelacije (Slika 3) prikazuje međusobne odnose ključnih značajki. Najveća korelacija s ishodom utakmice primijećena je kod varijabli *elo_diff* i *rating_diff*, što potvrđuje da je razlika u kvaliteti timova najvažniji prediktor. S druge strane, taktički atributi poput brzine igre (*buildUpPlaySpeed*) pokazuju zanemarivu linearnu korelaciju s konačnim ishodom.

3 Implementacija modela

3.1 Neuronska mreža

3.2 XGBoost

3.3 Random forest

3.4 How to write Mathematics

L^AT_EX is great at typesetting mathematics. Let $X_1, X_2, \dots, X_n$ be a sequence of independent and identically distributed random variables with $E[X_i] = \mu$ and $\text{Var}[X_i] = \sigma^2 < \infty$, and let

$$S_n = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_i^n X_i$$

denote their mean. Then as n approaches infinity, the random variables $\sqrt{n}(S_n - \mu)$ converge in distribution to a normal $\mathcal{N}(0, \sigma^2)$.

3.5 How to add Citations and a References List

You can simply upload a `.bib` file containing your BibTeX entries, created with a tool such as JabRef. You can then cite entries from it, like this: [Gre93]. Just remember to specify a bibliography style, as well as the filename of the `.bib`. You can find a [video tutorial here](#) to learn more about BibTeX.

If you have an [upgraded account](#), you can also import your Mendeley or Zotero library directly as a `.bib` file, via the upload menu in the file-tree.

3.6 Good luck!

We hope you find Overleaf useful, and do take a look at our [help library](#) for more tutorials and user guides! Please also let us know if you have any feedback using the **Contact us** link at the bottom of the Overleaf menu — or use the contact form at <https://www.overleaf.com/contact>.

Literatura

[Gre93] George D. Greenwade. The Comprehensive Tex Archive Network (CTAN). *TUGBoat*, 14(3):342–351, 1993.